CAPÍTULO

# APLICACIÓN DEL MODELO DE MACHINE LEARNING

## Implementación, validación, ajuste y transferencia espacial mediante PyCaret en AWS SageMaker

---

Propósito del capítulo. Este capítulo documenta la aplicación computacional del modelo predictivo desarrollado para estimar el Índice de Vulnerabilidad Climática (IVC), desde la preparación del conjunto de datos y la selección del algoritmo hasta la validación, el ajuste de hiperparámetros, la generación de predicciones y la transferencia espacial hacia Medellín y Cali. La implementación fue comprobada en un entorno de AWS SageMaker utilizando PyCaret y componentes del ecosistema Python para análisis geoespacial y almacenamiento en Amazon S3.

La exposición se estructura como evidencia reproducible del procedimiento seguido en el desarrollo experimental. Se diferencian explícitamente tres niveles: (i) evaluación del modelo en Bogotá, donde existe la variable objetivo; (ii) finalización del modelo para producción; y (iii) inferencia o transferencia espacial sobre Medellín y Cali, donde las salidas representan estimaciones del modelo y no una validación supervisada local.

Unidad experimental: manzanas/polígonos censales y variables socioeconómicas, catastrales y climáticas.

Variable objetivo: ivc_n, índice numérico de vulnerabilidad climática normalizado.

Modelo seleccionado: LightGBM (Light Gradient Boosting Machine), mediante PyCaret.

Plataforma: AWS SageMaker; almacenamiento y transferencia de artefactos mediante Amazon S3.

# 1. Objetivo de la aplicación computacional

La fase de aplicación tuvo como objetivo transformar el modelo conceptual de vulnerabilidad climática en un procedimiento predictivo ejecutable, evaluable y reutilizable. Para ello se utilizó un enfoque de regresión supervisada, dado que el IVC fue tratado como una variable continua. El modelo debía aprender la relación entre un conjunto amplio de atributos territoriales y socioeconómicos y el valor observado de ivc_n en Bogotá.

La decisión de utilizar una metodología automatizada mediante PyCaret permitió comparar algoritmos bajo un mismo esquema experimental, establecer una línea base de desempeño, identificar el algoritmo con mejor comportamiento y posteriormente realizar un ajuste dirigido de hiperparámetros. Esta estrategia reduce la dependencia de decisiones manuales aisladas y facilita la trazabilidad del experimento.

# 2. Entorno tecnológico y reproducibilidad

El desarrollo fue ejecutado en AWS SageMaker. El material de trabajo registra la creación/uso de un entorno denominado pycaret_env y la instalación de PyCaret 3.3.2. El flujo integra Python, pandas para manipulación tabular, scikit-learn para particiones y métricas complementarias, LightGBM como estimador, GeoPandas y Shapely para la representación espacial, Contextily para cartografía base y awswrangler/boto3 para interacción con Amazon S3.

La arquitectura operacional puede resumirse como: datos → preparación → PyCaret → comparación → ajuste → validación → modelo final → almacenamiento en S3 → carga del modelo → inferencia espacial → mapas de predicción.

| Datos Bogotá | Preparación | PyCaret | Validación | Modelo final |
|---|---|---|---|---|
| 43.408 registros<br>variables territoriales | Eliminación de fuga<br>tratamiento de atípicos | Regresión<br>LightGBM | k-fold +<br>splits train/test | Artefacto<br>reutilizable |
| ↓ | ↓ | ↓ | ↓ | ↓ |
| S3 / SageMaker | Feature set | $R^2$, RMSE,<br>MAE, MSE | 60/40 a 90/10 | S3 → inferencia |

Figura 1. Flujo general de aplicación, validación y despliegue del modelo.

# 3. Preparación del conjunto de datos para el aprendizaje

El conjunto utilizado para la modelación en Bogotá contiene 43.408 observaciones. La estructura original incluyó variables de identificación territorial, localización geográfica, características físicas, variables demográficas, educativas, de ocupación, servicios públicos, uso del suelo y variables climáticas. La exploración inicial registró 62 columnas; posteriormente se excluyeron variables que podían introducir fuga de información respecto de la variable objetivo.

En particular, se eliminaron ivc_formula, categoria_ivc y perfil_vulnerabilidad. Esta decisión es metodológicamente importante: las dos primeras contienen información directamente asociada con la construcción o categorización del IVC y la tercera corresponde a una clasificación derivada. Mantenerlas como predictores habría permitido al algoritmo reconstruir el objetivo a partir de información que conceptualmente pertenece a la respuesta, produciendo una estimación artificialmente optimista.

Después del filtrado, el experimento de validación complementaria reportó una matriz de predictores de 43.408 × 58 y un vector objetivo de 43.408 observaciones. La variable objetivo utilizada por PyCaret fue ivc_n.

## 3.1. Tratamiento de valores atípicos

El material experimental indica la exclusión de valores atípicos mediante el rango intercuartílico (IQR). Este procedimiento se aplicó como estrategia de control de observaciones extremas para reducir su influencia sobre el entrenamiento, particularmente relevante en variables territoriales y de conteo que presentan distribuciones asimétricas. La decisión debe interpretarse como un mecanismo de robustez y no como una afirmación de que todo valor extremo sea necesariamente un error de medición.

## 3.2. Naturaleza de las variables

El conjunto combina variables numéricas y categóricas. PyCaret se encargó del flujo de preprocesamiento requerido por el experimento, incluyendo la codificación de variables categóricas. Esto resulta especialmente relevante para atributos como NMB_LC_CM y TP_LC_CM, que representan categorías territoriales.

# 4. Configuración del experimento en PyCaret

Se configuró un experimento de regresión con ivc_n como variable objetivo y una semilla fija (session_id=123) para favorecer la reproducibilidad. La comparación automática permitió establecer el comportamiento relativo de múltiples regresores bajo condiciones homogéneas.

## 4.1. Código central de configuración

```
from pycaret.regression import setup, create_model, pull, get_config

experiment = setup(
    data=df,
    target='ivc_n',
    session_id=123
)

best_model = create_model(
    'lightgbm',
    verbose=False,
    verbosity=-1
)

metricas_lightgbm = pull()
```

El uso de create_model('lightgbm') permitió evaluar LightGBM con su configuración inicial y obtener una primera referencia de desempeño. La selección no se hizo únicamente por el valor de $R^2$: se consideraron simultáneamente MAE, RMSE, MSE y las métricas adicionales reportadas por PyCaret.

## 4.2. Comparación inicial de modelos

La comparación automática mostró que LightGBM presentó el mejor comportamiento entre los modelos relevantes evaluados. Para la configuración base se obtuvo MAE = 0,0159, RMSE = 0,0260 y $R^2$ = 0,8856 en la validación cruzada reportada por PyCaret. Como referencias inmediatas, Extra Trees y Random Forest presentaron RMSE de 0,0267 y $R^2$ cercanos a 0,8795 y 0,8794, respectivamente; Gradient Boosting alcanzó RMSE de 0,0291 y $R^2$ de 0,8566.

Tabla 1. Resultados principales de la comparación automática.

| Modelo | MAE | RMSE | $R^2$ |
|---|---|---|---|
| LightGBM | 0,0159 | 0,0260 | 0,8856 |
| Extra Trees | ≈0,016–0,017 | 0,0267 | 0,8795 |
| Random Forest | ≈0,016–0,017 | 0,0267 | 0,8794 |
| Gradient Boosting | ≈0,018–0,020 | 0,0291 | 0,8566 |
| Decision Tree | ≈0,024 | 0,0390 | 0,7423 |

# 5. Ajuste de hiperparámetros (fine-tuning)

Una vez identificado LightGBM como el algoritmo de referencia, se realizó una búsqueda de hiperparámetros. Debido al costo computacional del procedimiento sobre el conjunto completo, el desarrollo documenta una etapa de tuning sobre una muestra del 25 % de los datos, utilizada exclusivamente para encontrar una configuración prometedora. Posteriormente, los hiperparámetros ganadores se aplicaron nuevamente sobre el conjunto completo.

## 5.1. Estrategia de búsqueda

```
df_muestra = df.sample(frac=0.25, random_state=123)

experiment_tuning = setup(
    data=df_muestra,
    target='ivc_n',
    session_id=123
)

tuned_model = tune_model(
    best_model_muestra,
    optimize='RMSE',
    n_iter=8,
    fold=2,
    search_library='scikit-learn',
    search_algorithm='random',
    choose_better=True,
    custom_grid={
        'n_estimators': [100, 200],
        'num_leaves': [20, 31],
        'learning_rate': [0.1, 0.2],
        'max_depth': [8, 15],
        'n_jobs': [-1]
    }
)
```

La optimización se orientó a minimizar RMSE, criterio coherente con la naturaleza continua del IVC y con el interés por reducir la magnitud promedio del error cuadrático. Se utilizó una búsqueda aleatoria de ocho iteraciones y validación de dos pliegues en la fase de ajuste.

## 5.2. Configuración ganadora

| Hiperparámetro | Valor seleccionado |
|---|---|
| boosting_type | gbdt |
| n_estimators | 200 |
| num_leaves | 20 |
| learning_rate | 0,1 |
| max_depth | 15 |
| n_jobs | -1 |
| random_state | 123 |
| verbosity | -1 |

Tabla 2. Hiperparámetros seleccionados en el proceso de fine-tuning.

La configuración final reduce deliberadamente la complejidad del árbol respecto de configuraciones más flexibles, particularmente mediante num_leaves=20. Esta restricción resultó consistente con el objetivo de mejorar la generalización y evitar que el modelo dependiera de estructuras excesivamente

específicas del conjunto de entrenamiento.

# 6. Entrenamiento del modelo final y validación

Con los hiperparámetros seleccionados se reconstruyó el experimento sobre el conjunto completo de Bogotá. La implementación utilizó nuevamente PyCaret y generó el estimador LightGBM con la configuración ganadora. El modelo final se sometió a validación cruzada y, adicionalmente, se evaluó mediante cuatro proporciones independientes de entrenamiento/prueba: 70/30, 80/20, 90/10 y 60/40.

## 6.1. Desempeño en validación cruzada

| Métrica | Media | Desv. estándar |
|---|---|---|
| MAE | 0,0155 | 0,0003 |
| MSE | ≈0,0007 | ≈0,0000 |
| RMSE | 0,0255 | ≈0,0000 |
| $R^2$ | 0,8898 | ≈0,005–0,008 |
| RMSLE | 0,0220 | ≈0,0007 |

Tabla 3. Desempeño medio del LightGBM afinado en validación cruzada.

Frente al modelo base ($R^2$=0,8856; RMSE=0,0260), la configuración afinada alcanzó $R^2$=0,8898 y RMSE=0,0255 en la validación reportada. La mejora es moderada, pero consistente en dirección: menor error y mayor proporción de variabilidad explicada.

## 6.2. Robustez frente a diferentes particiones

| Partición | Entrenamiento | Prueba | $R^2$ | MAE | RMSE |
|---|---|---|---|---|---|
| 70/30 | 30.385 | 13.023 | 0,892391 | 0,015680 | 0,025370 |
| 80/20 | 34.726 | 8.682 | 0,892157 | 0,015652 | 0,025446 |
| 90/10 | 39.067 | 4.341 | 0,899661 | 0,015419 | 0,024681 |
| 60/40 | 26.044 | 17.364 | 0,890834 | 0,015690 | 0,025521 |

Tabla 4. Evaluación del modelo final bajo diferentes particiones train/test.

La partición 90/10 obtuvo el menor RMSE (0,024681) y el mayor $R^2$ (0,899661). Sin embargo, el resultado más relevante metodológicamente es la estabilidad: las cuatro particiones produjeron $R^2$ entre 0,890834 y 0,899661 y RMSE entre 0,024681 y 0,025521. Por tanto, la conclusión no debe reducirse a que 90/10 es 'la mejor' configuración, sino a que el modelo conserva un desempeño similar cuando cambia la proporción de datos reservados para prueba.

## 7. Interpretabilidad: importancia de variables

Para complementar la evaluación predictiva se examinó la importancia de las variables del LightGBM afinado. La importancia utilizada corresponde a la ganancia acumulada reportada por el estimador. Posteriormente, las variables transformadas por la codificación interna se agruparon por variable original para facilitar la interpretación.

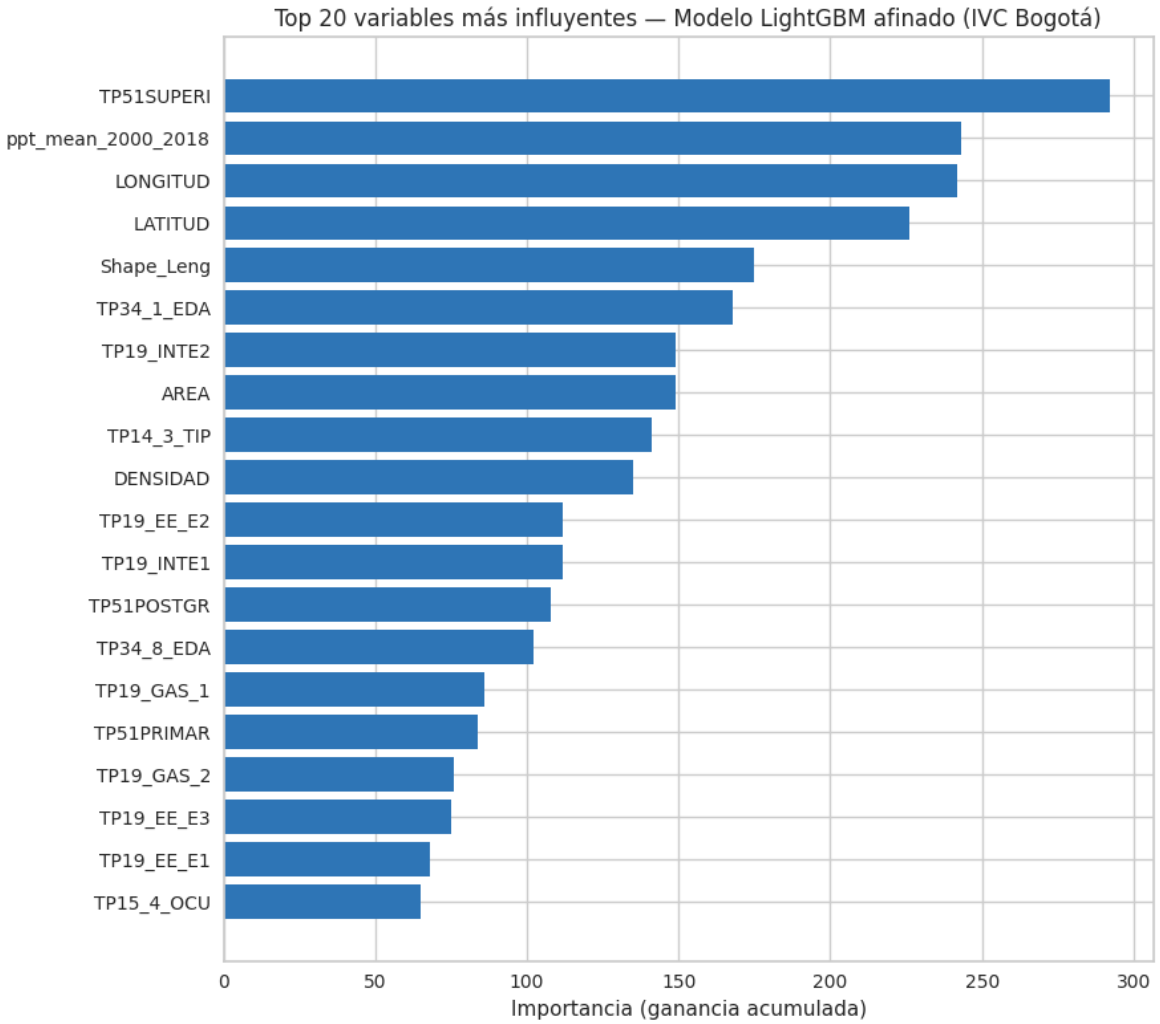



Figura 2. Veinte variables con mayor importancia en el modelo LightGBM afinado para Bogotá.

| Variable | Importancia |
|---|---|
| TP51SUPERI | 292 |
| ppt_mean_2000_2018 | 243 |
| LONGITUD | 242 |
| LATITUD | 226 |
| Shape_Leng | 175 |
| TP34_1_EDA | 168 |
| TP19_INTE2 | 149 |
| AREA | 149 |
| TP14_3_TIP | 141 |
| DENSIDAD | 135 |

Tabla 5. Ejemplos de las variables con mayor ganancia acumulada.

El resultado muestra una combinación de dimensiones espaciales, climáticas y socioeconómicas. Destacan TP51SUPERI, la precipitación media histórica (ppt_mean_2000_2018), longitud y latitud, así como variables de forma territorial, educación, densidad y servicios. La presencia simultánea de variables climáticas y de contexto territorial es coherente con la naturaleza multidimensional del IVC.

Precaución interpretativa: importancia de variable no equivale a causalidad. El ranking indica contribución predictiva dentro del modelo, pero no demuestra por sí mismo que una variable cause cambios en la vulnerabilidad.

# 8. Finalización, persistencia y uso como modelo de producción

Una vez definida la configuración, el modelo se entrenó sobre el conjunto completo y se preparó para reutilización. El artefacto fue almacenado en Amazon S3 y posteriormente recuperado desde SageMaker para ejecutar inferencias sobre nuevos conjuntos de datos. Esta separación entre entrenamiento e inferencia es fundamental para evitar reentrenamientos innecesarios y permite que el mismo objeto predictivo sea aplicado de forma consistente.

## 8.1. Esquema de persistencia

```
# Carga del modelo persistido
from pycaret.regression import load_model, predict_model
import awswrangler as wr

wr.s3.download(
    path='s3://databogota/modelos/modelo_ivc_bogota_final_tuned.pkl',
    local_file='modelo_ivc_bogota_final_tuned.pkl'
)

modelo_produccion = load_model(
    'modelo_ivc_bogota_final_tuned'
)
```

La implementación documentada utiliza un bucket de datos para entrada y un bucket destinado a predicciones. Los artefactos incluyen el modelo ajustado, archivos CSV de resultados y productos cartográficos. En consecuencia, AWS no fue utilizado únicamente como lugar de ejecución, sino como componente de trazabilidad y almacenamiento del ciclo de vida del modelo.

## 8.2. Alineación de variables antes de la inferencia

Para la transferencia a nuevas ciudades se implementó una función de alineación de columnas. Esta función consulta las características esperadas por el pipeline entrenado, agrega columnas ausentes con valores de respaldo y devuelve únicamente las variables en el orden requerido. Para atributos categóricos territoriales se utilizó 'Desconocido' cuando correspondía; para variables numéricas ausentes se utilizó 0. Esta etapa reduce errores derivados de diferencias estructurales entre los archivos de Bogotá, Medellín y Cali.

## 9. Aplicación del modelo: predicción espacial en Bogotá

La aplicación del modelo en Bogotá permitió transformar la salida numérica del regresor en una representación espacial del IVC predicho. La predicción se integró con coordenadas geográficas y geometrías territoriales para producir cartografía a nivel de unidad espacial. El mapa resultante evidencia una distribución heterogénea de los valores estimados y permite identificar concentraciones relativas de mayor y menor vulnerabilidad.

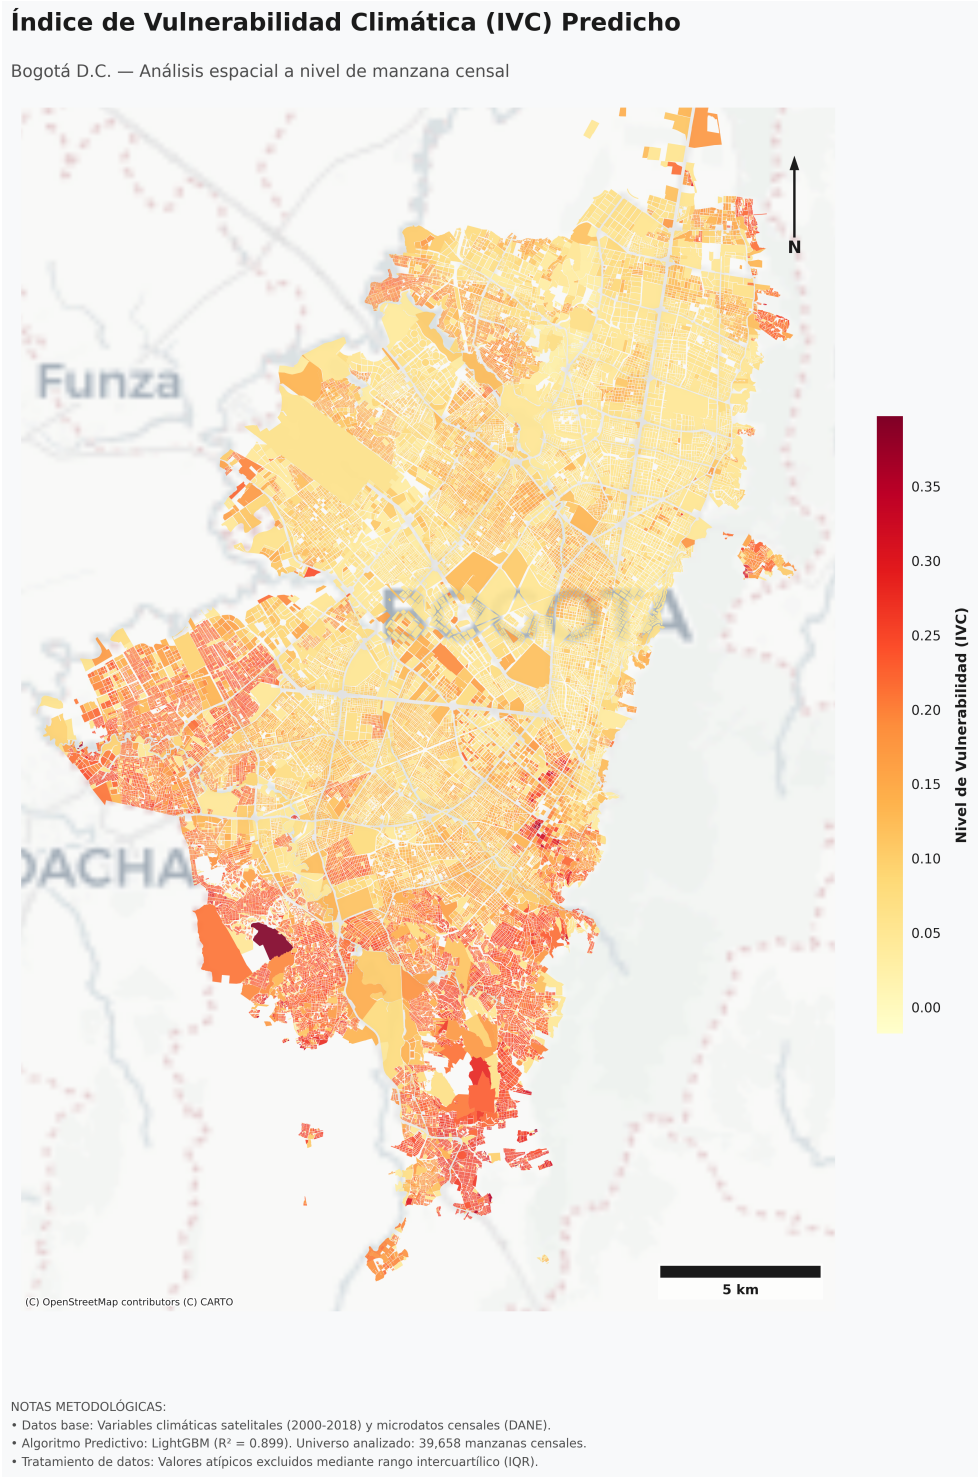



Figura 3. IVC predicho para Bogotá a nivel de manzana censal. La escala cromática representa el valor continuo estimado por el modelo.

En el mapa, los valores más altos se concentran visualmente en sectores donde el gradiente se desplaza hacia tonalidades más intensas. La lectura correcta es relativa al rango mostrado: el mapa representa una superficie de predicción continua y no debe confundirse con una clasificación

normativa de vulnerabilidad.

## 10. Transferencia espacial hacia Medellín

El modelo entrenado en Bogotá fue cargado desde S3 y aplicado sobre los datos preparados para Medellín. La inferencia se ejecutó mediante predict_model, y la salida prediction_label fue renombrada como IVC_predicho. Posteriormente, las coordenadas de longitud y latitud se transformaron en objetos espaciales para su representación cartográfica.

El universo cartográfico mostrado corresponde a aproximadamente 9.906 polígonos catastrales, de acuerdo con la nota metodológica incorporada en el producto gráfico. El resultado debe interpretarse como una transferencia de dominio: el modelo aprende relaciones en Bogotá y las utiliza para estimar IVC en Medellín.

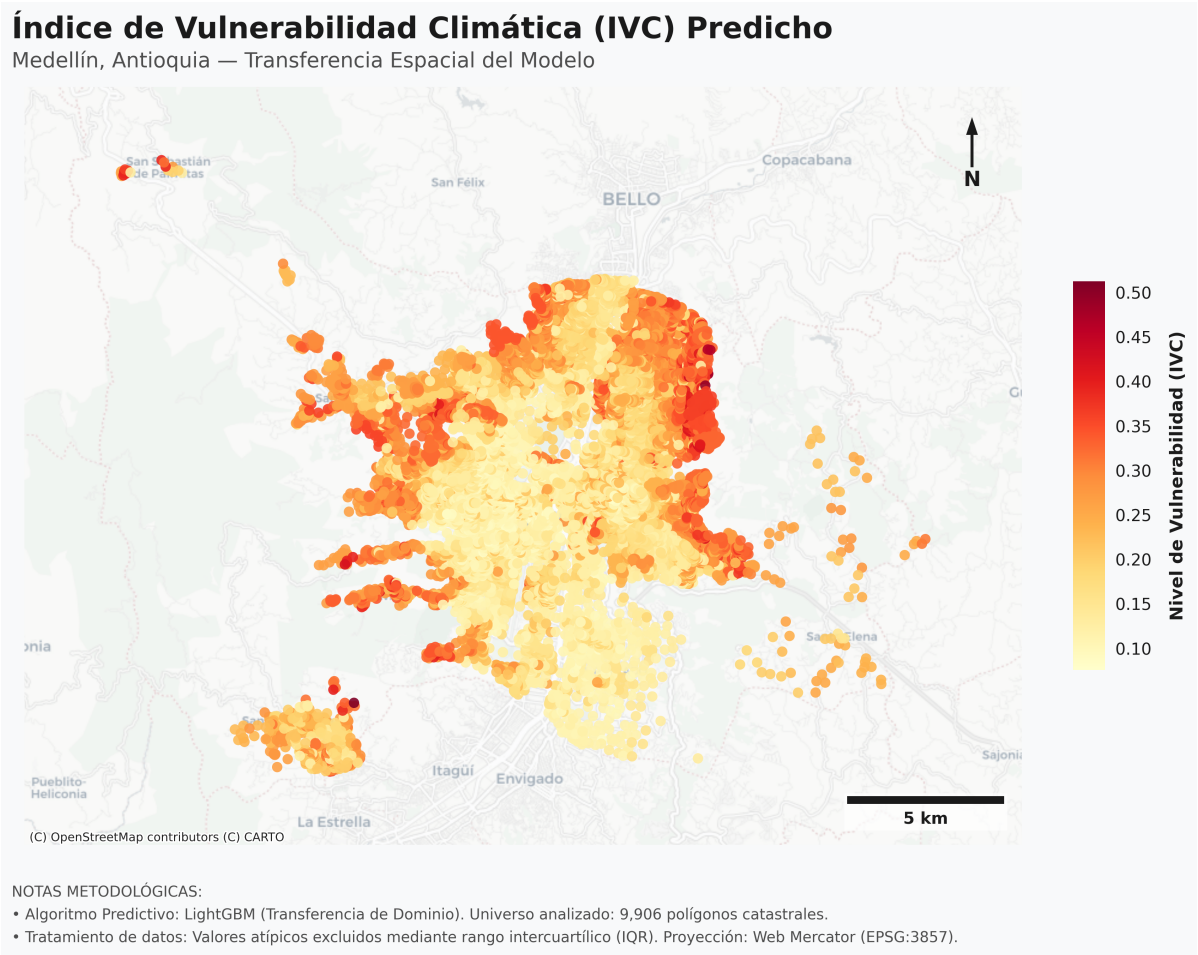



Figura 4. Transferencia espacial del modelo LightGBM hacia Medellín, Antioquia.

Limitación de validación: en ausencia de una variable objetivo local independiente para Medellín dentro del experimento documentado, no se reportan $R^2$, MAE o RMSE para esta ciudad. Los valores visualizados son predicciones del modelo, no observaciones verificadas.

## 11. Transferencia espacial hacia Cali

El mismo artefacto de producción fue aplicado a los datos de Cali siguiendo la misma secuencia: lectura desde S3, alineación de variables, inferencia, recuperación de coordenadas y construcción de la representación espacial. La homogeneidad del procedimiento es importante para que las diferencias observadas entre ciudades se atribuyan al territorio y a los datos de entrada, y no a cambios arbitrarios en el pipeline.

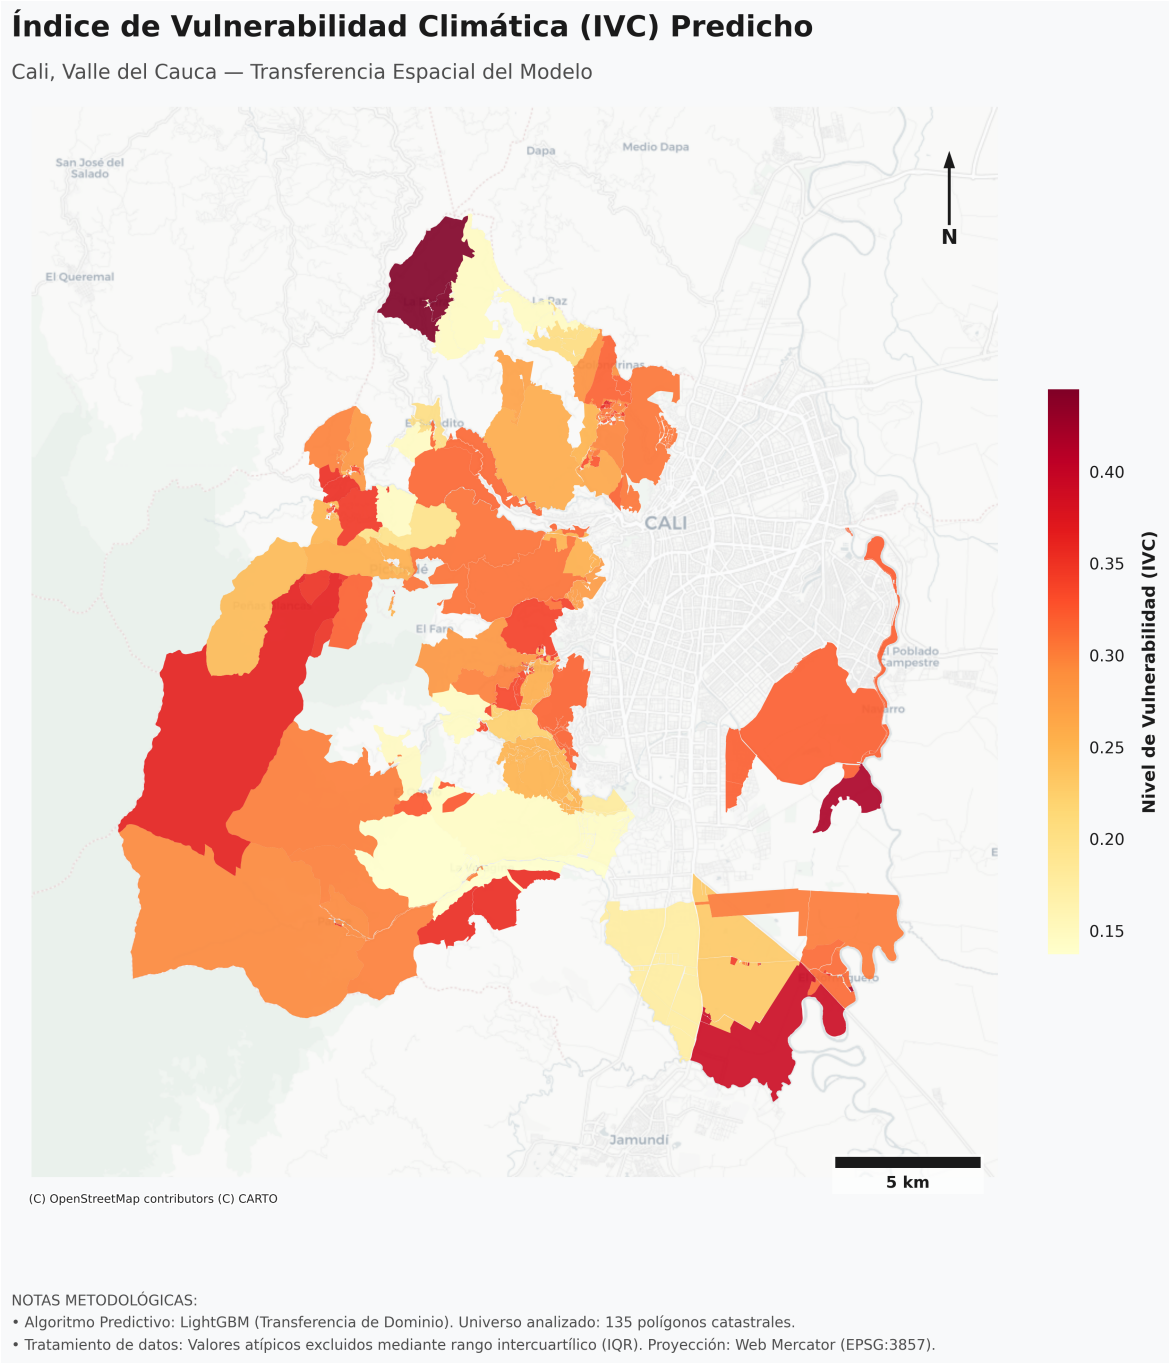



Figura 5. Transferencia espacial del modelo LightGBM hacia Cali, Valle del Cauca.

El producto cartográfico muestra una distribución espacial diferenciada del IVC predicho. Los sectores con tonalidades más intensas representan valores estimados relativamente mayores dentro del rango mostrado para Cali. Nuevamente, esta salida es una inferencia del modelo entrenado en Bogotá y no una medición local del IVC.

## 12. Flujo técnico de inferencia y generación cartográfica

```
# Inferencia
pred_medellin = predict_model(
    modelo_produccion,
    data=df_medellin_listo
)
pred_medellin.rename(
    columns={'prediction_label': 'IVC_predicho'},
    inplace=True
)

# Conversión a GeoDataFrame
gdf_pred_med = gpd.GeoDataFrame(
    pred_medellin,
    geometry=[
        Point(xy) for xy in zip(
            pred_medellin['LONGITUD'],
            pred_medellin['LATITUD']
        )
    ],
    crs='EPSG:4326'
)
```

La representación final se realizó mediante GeoPandas y Matplotlib, con reproyección a Web Mercator (EPSG:3857) para integrar cartografía base. Se incorporaron escala gráfica, flecha de norte, barra de color y notas metodológicas. Esta normalización cartográfica favorece la lectura comparativa y la comunicación de los resultados.

## 13. Interpretación integrada de los resultados

Los resultados permiten sostener que el modelo LightGBM constituye una alternativa adecuada para la estimación continua del IVC dentro del universo analizado en Bogotá. La evidencia principal está dada por el $R^2$ cercano a 0,89, el RMSE alrededor de 0,025–0,026 y la estabilidad observada al modificar la partición de entrenamiento y prueba.

La diferencia entre el modelo base y el modelo afinado es cuantitativamente moderada, pero metodológicamente relevante. El ajuste reduce RMSE de 0,0260 a 0,0255 en la validación reportada y eleva $R^2$ de 0,8856 a aproximadamente 0,8898. En las particiones independientes, el $R^2$ se mantiene en torno a 0,891–0,900. Esto indica que la mejora no depende exclusivamente de una sola partición.

La transferencia hacia Medellín y Cali amplía la utilidad aplicada del modelo al convertirlo en una herramienta de exploración espacial. Sin embargo, esta fase debe considerarse inferencia fuera del dominio de entrenamiento. Las diferencias de distribución entre ciudades pueden producir desplazamiento de dominio (domain shift), por lo que una futura etapa de investigación debería incorporar datos locales observados y una validación externa específica.

## 14. Consideraciones metodológicas y limitaciones

Primera limitación: validación externa. La evaluación cuantitativa reportada corresponde al dominio de Bogotá. Las predicciones para Medellín y Cali no cuentan, en el material suministrado, con valores observados independientes del IVC que permitan calcular métricas supervisadas locales.

Segunda limitación: transferencia de dominio. El hecho de que el modelo tenga buen desempeño en Bogotá no garantiza automáticamente el mismo nivel de precisión en otras ciudades. Variables como estructura urbana, condiciones climáticas, patrones socioeconómicos y disponibilidad/codificación de datos pueden diferir.

Tercera limitación: interpretación de importancia. El ranking de variables del LightGBM es una medida de utilidad predictiva interna. No constituye una prueba de causalidad ni reemplaza análisis estadísticos específicos sobre mecanismos explicativos.

Cuarta limitación: sensibilidad al tratamiento de atípicos. La exclusión de valores extremos mediante IQR mejora la estabilidad del entrenamiento, pero puede eliminar observaciones territorialmente legítimas. En una fase posterior convendría realizar un análisis de sensibilidad con y sin este tratamiento.

## 15. Reproducibilidad y trazabilidad del experimento

La reproducibilidad se fortaleció mediante una semilla fija (123), registro de hiperparámetros, exportación de métricas a archivos CSV, persistencia del modelo y almacenamiento de resultados en S3. Además, el pipeline de inferencia consulta las características esperadas por el modelo antes de predecir, reduciendo el riesgo de incompatibilidades de columnas.

Desde la perspectiva de MLOps, el procedimiento ya contiene elementos esenciales de un ciclo reproducible: entrenamiento controlado, evaluación, serialización, almacenamiento, recuperación, inferencia y generación de productos. Como evolución natural, podría incorporarse versionamiento formal del dataset, registro de experimentos, monitoreo de deriva de datos y validación automática antes de cada transferencia espacial.

## 16. Conclusiones del capítulo

La aplicación computacional permitió comprobar que el modelo de regresión LightGBM puede aprender relaciones complejas entre variables territoriales, socioeconómicas y climáticas para estimar el IVC en Bogotá. PyCaret proporcionó un marco sistemático para comparar modelos, seleccionar el algoritmo de referencia y ejecutar el ajuste de hiperparámetros.

El modelo afinado alcanzó $R^2$=0,8898 y RMSE=0,0255 en la validación cruzada documentada, mientras que la evaluación mediante diferentes particiones produjo $R^2$ entre 0,890834 y 0,899661. La partición 90/10 presentó el mejor resultado puntual, con RMSE=0,024681 y $R^2$=0,899661, aunque la estabilidad de las cuatro particiones es una evidencia más importante de robustez.

Finalmente, la implementación en AWS SageMaker y la persistencia del modelo en Amazon S3 permitieron llevar el resultado experimental a una fase de inferencia reutilizable. La transferencia espacial hacia Medellín y Cali demuestra la posibilidad de aplicar el modelo a nuevos territorios, pero también establece claramente la necesidad de validación externa antes de utilizar las predicciones como evidencia definitiva para toma de decisiones.

Resultado central: el modelo queda establecido como un instrumento predictivo y espacialmente transferible, con desempeño cuantitativo comprobado en Bogotá y con una ruta técnica reproducible para su aplicación en otros contextos urbanos.