CAPÍTULO 4

APLICACIÓN DEL MODELO DE MACHINE LEARNING

Entrenamiento, validación, evaluación y transferencia espacial del modelo LightGBM

Nota metodológica de apertura. La selección de la configuración experimental no se realizó de manera arbitraria. En una fase previa, ejecutada en AWS SageMaker mediante PyCaret, se compararon distintas proporciones de entrenamiento y prueba y se examinó el comportamiento relativo de modelos de boosting. Esta fase permitió establecer el escenario computacional que posteriormente se formalizó en un segundo entorno de desarrollo. Por tanto, el presente capítulo no repite la selección inicial: ejecuta, evalúa y documenta en profundidad la configuración previamente seleccionada.

La validación previa en SageMaker constituye el antecedente experimental que sustenta el uso de una partición 90/10. El segundo escenario, implementado con LightGBM nativo en Google Colab, se utiliza como una replicación computacional y evaluación detallada de la configuración seleccionada. La coincidencia de los resultados en dirección y magnitud fortalece la consistencia del procedimiento, pero no se interpreta como una validación externa en sentido estadístico.

Objetivo: documentar el desempeño del modelo LightGBM para estimar el IVC_n en Bogotá, analizar su capacidad de generalización y generar predicciones espaciales transferibles a Medellín y Cali, diferenciando rigurosamente entre validación supervisada y transferencia de dominio.

Datos: 43.408 manzanas catastrales de Bogotá, 62 variables originales.

Variable objetivo: IVC_n, Índice de Vulnerabilidad Climática normalizado en [0,1].

Configuración ejecutada: LightGBM + pipeline scikit-learn + partición 90/10.

4.1 Introducción

El presente capítulo describe la aplicación formal del modelo de machine learning seleccionado para la estimación del Índice de Vulnerabilidad Climática normalizado (IVC_n) en manzanas catastrales de Bogotá, así como la generación posterior de predicciones espaciales y su transferencia metodológica hacia Medellín y Cali. El desarrollo parte de una decisión experimental ya establecida en una fase anterior: la selección de la proporción de entrenamiento y prueba y del enfoque algorítmico mediante PyCaret en AWS SageMaker.

La etapa previa en AWS SageMaker tuvo una función de selección y comprobación inicial de la configuración. Allí se exploraron las proporciones train/test de 70/30, 80/20, 60/40 y 90/10, y se compararon modelos de boosting mediante PyCaret. A partir de ese experimento se estableció como configuración de trabajo una partición 90/10 y un estimador de la familia Gradient Boosting, concretamente LightGBM. El propósito de este capítulo es diferente: aquí se ejecuta esa configuración en un segundo escenario computacional, se cuantifica su desempeño con mayor profundidad y se producen las salidas espaciales destinadas al análisis territorial.

Esta separación de etapas es importante para la trazabilidad de la investigación. La fase de AWS SageMaker responde a la pregunta ¿qué configuración conviene utilizar?, mientras que el presente capítulo responde a ¿cómo se comporta y qué resultados produce la configuración seleccionada cuando se implementa formalmente?. La coincidencia posterior de los resultados no se presenta como prueba de validez externa, sino como evidencia de consistencia y reproducibilidad computacional entre dos entornos de ejecución.

El flujo seguido comprende: (i) recuperación de la configuración seleccionada; (ii) preparación de los datos; (iii) control de fuga de información; (iv) división 90/10; (v) construcción del pipeline; (vi) entrenamiento de LightGBM; (vii) validación cruzada; (viii) evaluación hold-out; (ix) diagnóstico de sobreajuste y residuos; (x) interpretación de importancia de variables; (xi) generación y espacialización de predicciones; (xii) transferencia mediante un modelo independiente de coordenadas específicas de Bogotá; y (xiii) preparación del artefacto para reutilización.

Desde el punto de vista de una investigación de maestría, la principal contribución de esta etapa consiste en pasar de la selección automática de un algoritmo a una evaluación integral de su capacidad predictiva, estabilidad y utilidad territorial. De esta forma, las métricas cuantitativas, los diagnósticos gráficos y los mapas forman parte de una misma cadena de evidencia.

4.2 Antecedente experimental: validación de la partición Train/Test mediante PyCaret en AWS SageMaker

Antes de formalizar el pipeline definitivo se ejecutó un experimento independiente en AWS SageMaker utilizando PyCaret. Se empleó el conjunto bogota_ivc_thesis_ready.csv y el módulo de regresión de PyCaret. La variable train_size se modificó sistemáticamente entre 0,70, 0,80, 0,60 y 0,90, correspondientes a las particiones 70/30, 80/20, 60/40 y 90/10, y se comparó el comportamiento de modelos de boosting, entre ellos Gradient Boosting, LightGBM, CatBoost y XGBoost.

Este procedimiento permitió establecer un punto de partida objetivo para el desarrollo posterior: la partición 90/10 ofrecía un volumen amplio de observaciones para entrenamiento —aproximadamente 39.067 manzanas— y conservaba 4.341 observaciones para una evaluación independiente. La decisión se sustentó, por tanto, en el comportamiento observado durante la fase de comparación y no en una elección convencional o arbitraria.

Los resultados obtenidos en SageMaker fueron posteriormente contrastados con la ejecución formal de LightGBM en Google Colab. La configuración 90/10 produjo en este segundo escenario un R^2 de 0,877819 sobre el conjunto de prueba, valor coherente con el desempeño identificado durante la fase previa. Esta convergencia debe interpretarse como una comprobación de consistencia del procedimiento en dos entornos computacionales; no constituye por sí sola validación externa del modelo, puesto que ambos experimentos utilizan el mismo dominio territorial de referencia.

Esta precisión conceptual es relevante: la validación supervisada del desempeño se realiza con observaciones de Bogotá que disponen de IVC observado; la transferencia a Medellín y Cali, descrita posteriormente, corresponde a inferencia sobre nuevos territorios y requiere validación local independiente

para establecer métricas de error externas.

4.2.1 Justificación de la proporción 90/10

La selección de 90/10 se fundamenta en cuatro consideraciones experimentales:

- Mayor volumen de entrenamiento: aproximadamente 39.067 observaciones permiten al algoritmo aprender relaciones no lineales con mayor información disponible.
- Tamaño suficiente del conjunto de prueba: 4.341 manzanas constituyen una base amplia para estimar el error de generalización dentro de Bogotá.
- Comparación previa: las proporciones alternativas fueron examinadas en PyCaret antes de fijar el escenario definitivo.
- Consistencia entre implementaciones: la ejecución posterior con LightGBM nativo reprodujo el comportamiento esperado, lo que aporta evidencia de estabilidad computacional.

En consecuencia, el 90/10 debe entenderse como una decisión experimental previamente sustentada, no como una garantía universal de optimalidad para cualquier conjunto de datos. Su conveniencia se refiere específicamente al problema y al conjunto analizado en esta investigación.

4.3 Preparación del entorno y carga de datos

El pipeline definitivo se ejecutó en Google Colab con Python 3.13, utilizando las librerías pandas, numpy, scipy, seaborn, rich y lightgbm, además de componentes de scikit-learn para partición, preprocesamiento, validación y evaluación. El conjunto bogota_ivc_thesis_ready.csv contiene 43.408 registros y 62 variables. La variable objetivo, ivc_n, corresponde al IVC normalizado en el intervalo [0,1], con media muestral 0,1485 y desviación estándar 0,0772.

La transferencia entre el escenario de AWS y el escenario de Colab se realizó manteniendo el mismo universo analítico y la configuración experimental seleccionada previamente. De este modo, la segunda ejecución no busca competir con la primera, sino desarrollar con mayor detalle la evaluación del modelo elegido.

4.4 División Train/Test y construcción del pipeline

Conforme a la configuración previamente seleccionada, se aplicó una partición aleatoria de 90 % para entrenamiento y 10 % para prueba, con test_size=0,10 y random_state=42. Se excluyeron del vector de predictores las variables que constituyen componentes directos o derivados del cálculo del IVC, con el propósito de evitar fuga de información (data leakage). Entre ellas se encuentran ivc_formula, indice_exposicion, indice_sensibilidad, indice_deficit_adaptativo, indice_capacidad_adaptativa, indice_capacidad_adaptativa_segura, categoria_ivc y perfil_vulnerabilidad.

Se construyó un Pipeline de scikit-learn que integra el preprocesamiento y el estimador. Las variables numéricas se mantuvieron sin transformación, dado que los árboles de LightGBM no requieren estandarización; las variables categóricas se codificaron mediante One-Hot Encoding con handle_unknown='ignore'. El resultado fue una estructura serializable y reutilizable.

```
preprocessor = ColumnTransformer(
    transformers=[
        ('num', 'passthrough', numeric_features),
        ('cat', OneHotEncoder(
            handle_unknown='ignore',
            sparse_output=False
        ), categorical_features)
    ]
)

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.10, random_state=42
)

model_pipeline = Pipeline(steps=[
    ('preprocessor', preprocessor),
    ('regressor', lgb.LGBMRegressor(
        n_estimators=100,
        learning_rate=0.05,
        random_state=42,
        verbose=-1
    ))
```

```
])
```

El resultado fue de 39.067 observaciones para entrenamiento y 4.341 para prueba, manteniendo la proporción previamente establecida.

4.5 Entrenamiento formal del modelo LightGBM

Una vez fijados los datos y el pipeline, se realizó el entrenamiento formal sobre X_train, y_train y posteriormente se generaron predicciones para X_test. El escenario definitivo obtuvo MAE=0,017012, RMSE=0,027584 y R^2=0,877819.

Métrica	Valor
MAE	0,017012
RMSE	0,027584
R^2	0,877819

El R^2=0,877819 indica que el modelo explica aproximadamente el 87,8 % de la variabilidad observada del IVC_n en el conjunto de prueba. Este resultado constituye una evidencia de capacidad predictiva elevada dentro del dominio de Bogotá, pero debe interpretarse conjuntamente con MAE, RMSE, validación cruzada y análisis de residuos. No implica por sí mismo causalidad ni garantiza el mismo desempeño fuera del dominio de entrenamiento.

4.6 Validación cruzada K-Fold (k=10)

Para determinar si el desempeño dependía de una única partición aleatoria, se ejecutó validación cruzada de 10 particiones sobre el conjunto de entrenamiento. En cada fold se replicó el flujo de preprocesamiento y modelado. La configuración utilizada incorporó controles de complejidad mediante num_leaves=31, feature_fraction=0,8, bagging_fraction=0,8, bagging_freq=5 y min_child_samples=20.

Métrica	Media Test	Desv. Est. Test	Media Train
R^2	0,8757	±0,0058	0,8914
MAE	0,0170	±0,0004	0,0162
RMSE	0,0271	±0,0008	0,0254

La desviación estándar de R^2 (0,0058) es baja frente a la magnitud de la métrica, lo que indica estabilidad ante diferentes subconjuntos del entrenamiento. La diferencia entre entrenamiento y validación también es moderada. En consecuencia, la evidencia conjunta apunta a una capacidad de generalización interna estable, aunque no reemplaza una validación espacial independiente.

El análisis de residuos complementario presentó un sesgo medio de 0,00028, prácticamente centrado en cero. El percentil 95 del error absoluto fue 0,061 y el percentil 99 fue 0,099, mostrando que los errores más altos se concentran en una fracción reducida de observaciones.

4.7 Evaluación en el conjunto de prueba (hold-out 10 %)

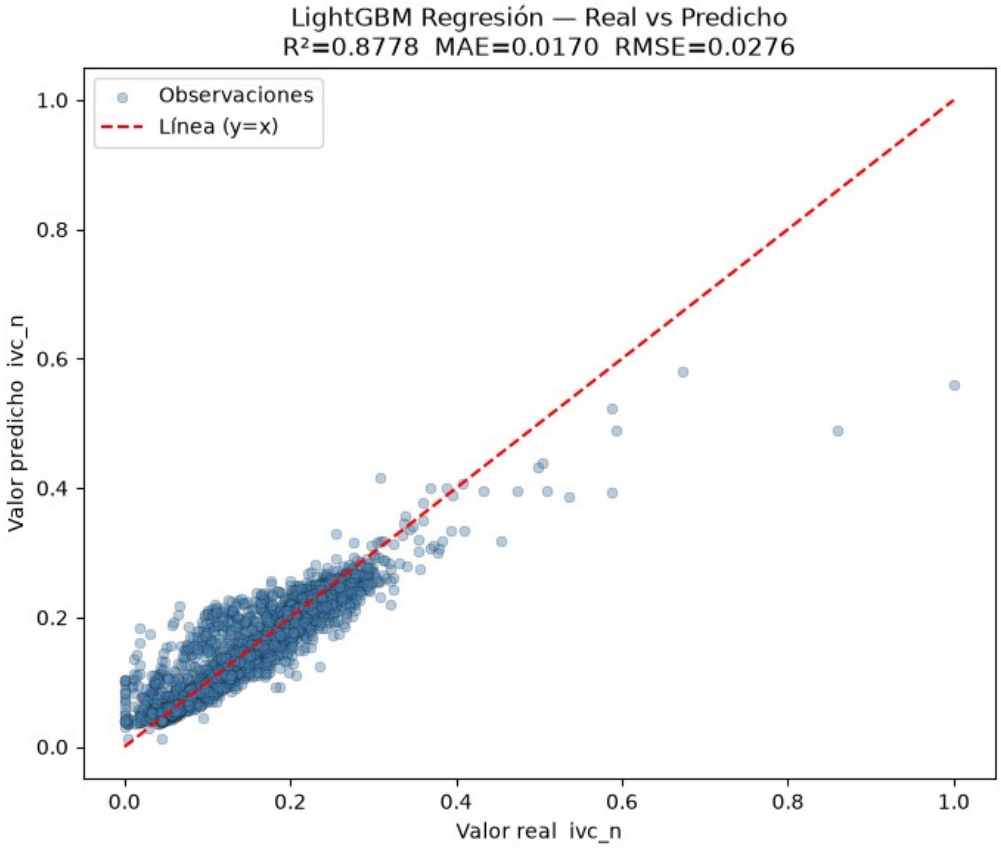


Figura 1. Valores reales frente a valores predichos del IVC_n en el conjunto de prueba. R^2=0,8778, MAE=0,0170 y RMSE=0,0276.

La nube de puntos se concentra alrededor de la línea de identidad, especialmente en el intervalo de vulnerabilidad baja y media (0,0–0,3). Se observa una tendencia de subestimación en valores extremos superiores (IVC_n>0,6). Esta característica es relevante porque indica que el modelo representa adecuadamente la mayor parte de la distribución, pero puede suavizar los casos extremos debido a la menor frecuencia de observaciones en la cola superior.

4.8 Análisis de sobreajuste y capacidad de generalización

Métrica	Train	Test	Brecha absoluta
R^2	0,8900	0,8778	0,0121
MAE	0,0164	0,0170	0,0006
RMSE	0,0255	0,0276	0,0020

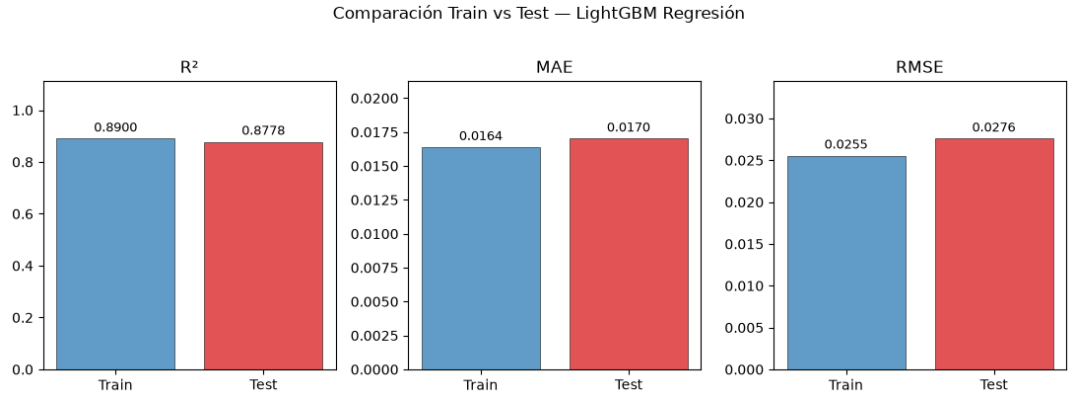


Figura 2. Comparación de métricas entre entrenamiento y prueba.

La brecha de R^2 de aproximadamente 0,0121 y las diferencias reducidas en MAE y RMSE no muestran evidencia de sobreajuste severo. El desempeño sobre datos no vistos permanece cercano al observado durante el entrenamiento. Esta conclusión se limita al esquema de partición utilizado y se complementa con la validación cruzada de 10 folds.

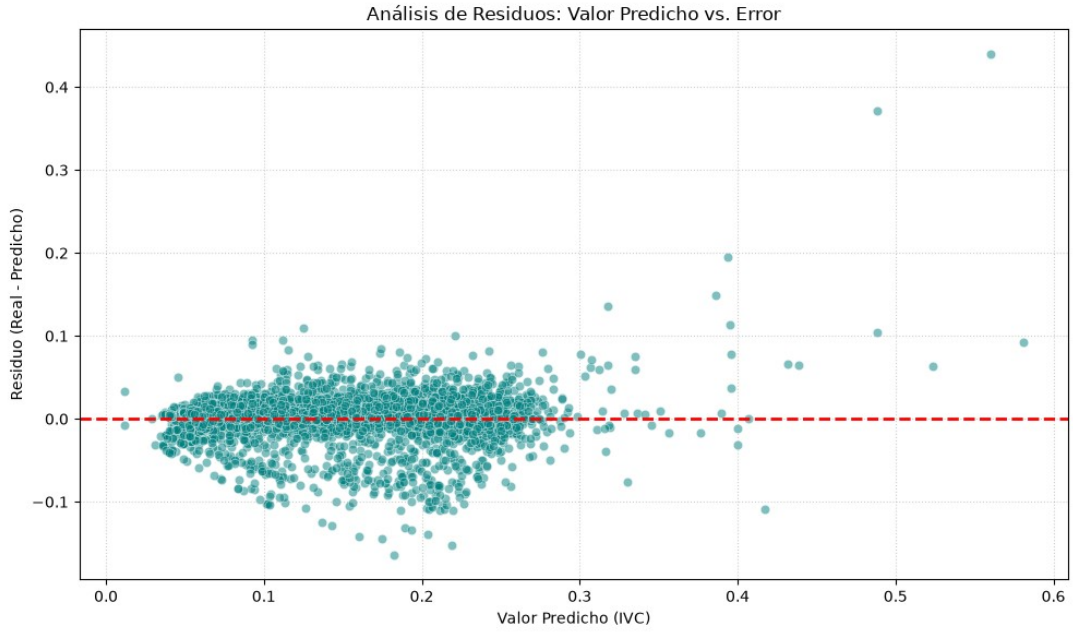


Figura 3. Residuos: valor predicho frente al error (real − predicho) en el conjunto de prueba.

Los residuos se distribuyen alrededor de cero sin un patrón sistemático dominante. Se identifican observaciones atípicas con residuos superiores a 0,15 en la zona de predicciones medias. Estas observaciones deben considerarse oportunidades de análisis posterior, ya que podrían corresponder a unidades con combinaciones socioeconómicas o climáticas poco frecuentes en el conjunto de entrenamiento.

4.9 Importancia de variables predictoras

La importancia de variables se calculó mediante gain, que representa la contribución acumulada de una variable a la reducción de la función de pérdida en las divisiones de los árboles. El resultado permite identificar qué atributos aportan mayor capacidad predictiva al modelo, pero no debe interpretarse como evidencia de causalidad.

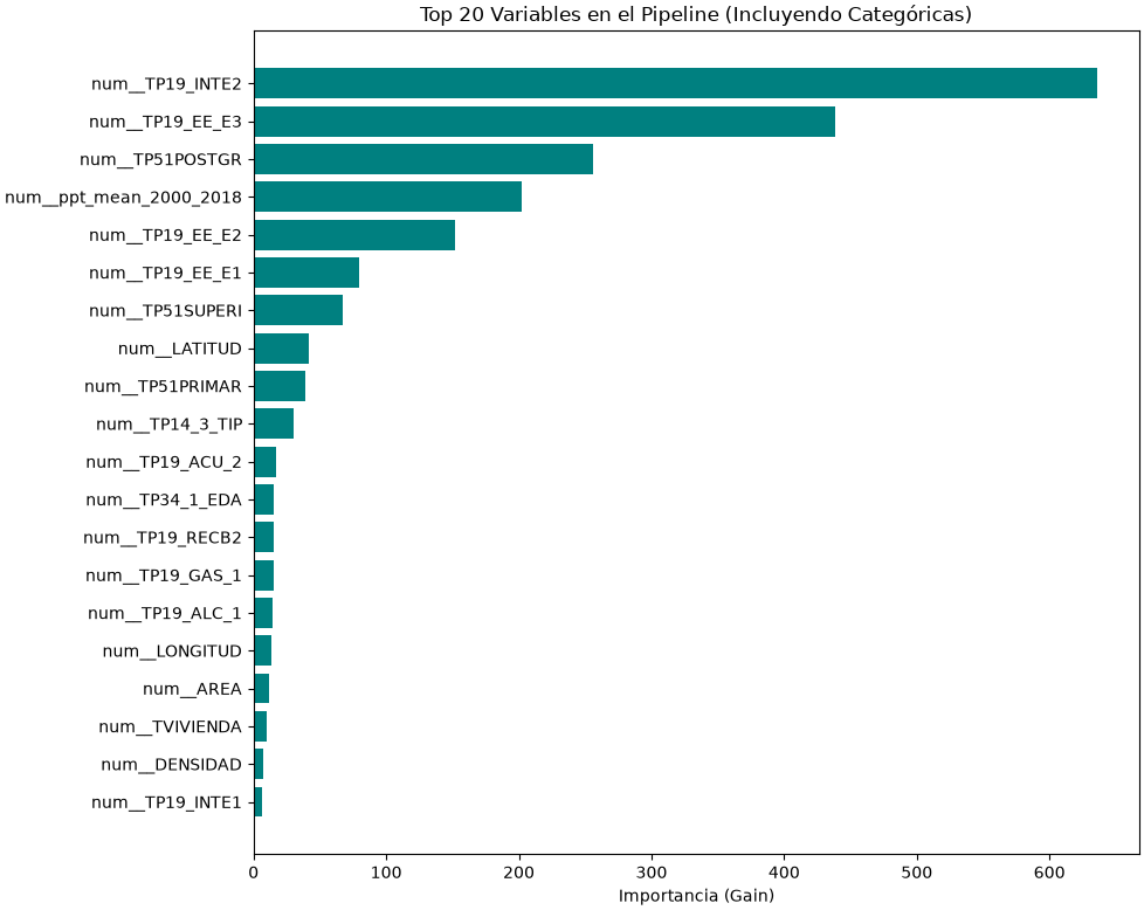


Figura 4. Top 20 variables predictoras según importancia por ganancia (gain).

La interpretación agregada permite reconocer cinco dimensiones: conectividad y capital social; estratificación socioeconómica; nivel educativo; exposición climática —incluida la precipitación histórica 2000–2018—; y componentes espaciales. La presencia de variables socioeconómicas y climáticas simultáneamente es consistente con el carácter multidimensional del IVC.

Debe evitarse una lectura causal directa del ranking. Por ejemplo, que TP19_INTE2 presente alta ganancia significa que la variable es útil para la predicción dentro del modelo; no demuestra por sí sola que el acceso a internet cause una reducción de la vulnerabilidad. La interpretación causal requeriría diseños y métodos específicos distintos al aprendizaje supervisado empleado aquí.

4.10 Comparación puntual: IVC real vs. IVC predicho

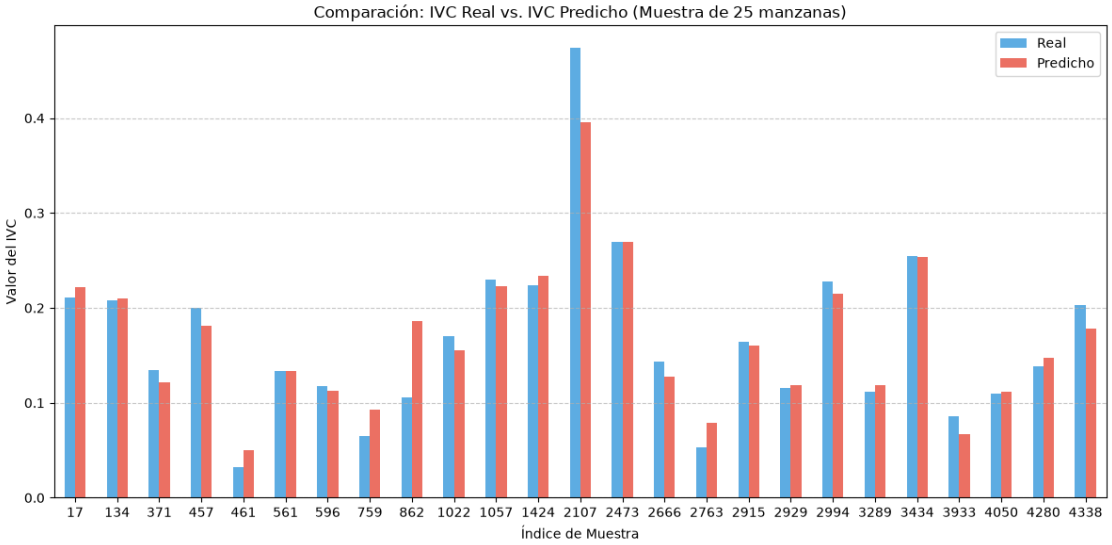


Figura 5. Comparación entre IVC real e IVC predicho para una muestra aleatoria de 25 manzanas del conjunto de prueba.

La comparación puntual permite auditar la salida del modelo a nivel de unidad espacial. En la muestra examinada, las predicciones reproducen de manera cercana el orden relativo y la magnitud del IVC observado, aunque persisten diferencias individuales que son coherentes con los errores resumidos mediante MAE y RMSE.

4.11 Predicciones generadas por el modelo

El modelo produjo 4.341 predicciones correspondientes al conjunto de prueba de Bogotá. Cada registro conserva su localización y permite asociar el IVC observado con el IVC estimado. Esta trazabilidad es relevante para la auditoría del modelo y para la integración posterior con Sistemas de Información Geográfica.

Latitud	Longitud	IVC real	IVC predicho
4,611383	−74,15216	0,1090	0,0936
4,532801	−74,15265	0,3350	0,3110
4,569291	−74,10521	0,1980	0,2050
4,684844	−74,13520	0,0870	0,0790
4,617878	−74,08890	0,1620	0,1580

La salida se exportó a archivos tabulares para facilitar su integración con QGIS y otros sistemas de análisis espacial, utilizando EPSG:4326 (WGS 84).

4.11.1 Localidades con mayor vulnerabilidad predicha

Ranking	Localidad	IVC predicho promedio
1	Usme	0,222925
2	San Cristóbal	0,200016
3	Ciudad Bolívar	0,194829
4	Bosa	0,190758
5	Rafael Uribe Uribe	0,176246

Las localidades con mayores promedios predichos se concentran principalmente en sectores periféricos del sur y suroriente de Bogotá. Esta distribución es compatible con los patrones espaciales observados en los datos; sin embargo, la coincidencia espacial no debe interpretarse como prueba causal de que una variable particular origine la vulnerabilidad.

4.11.2 Espacialización de las predicciones

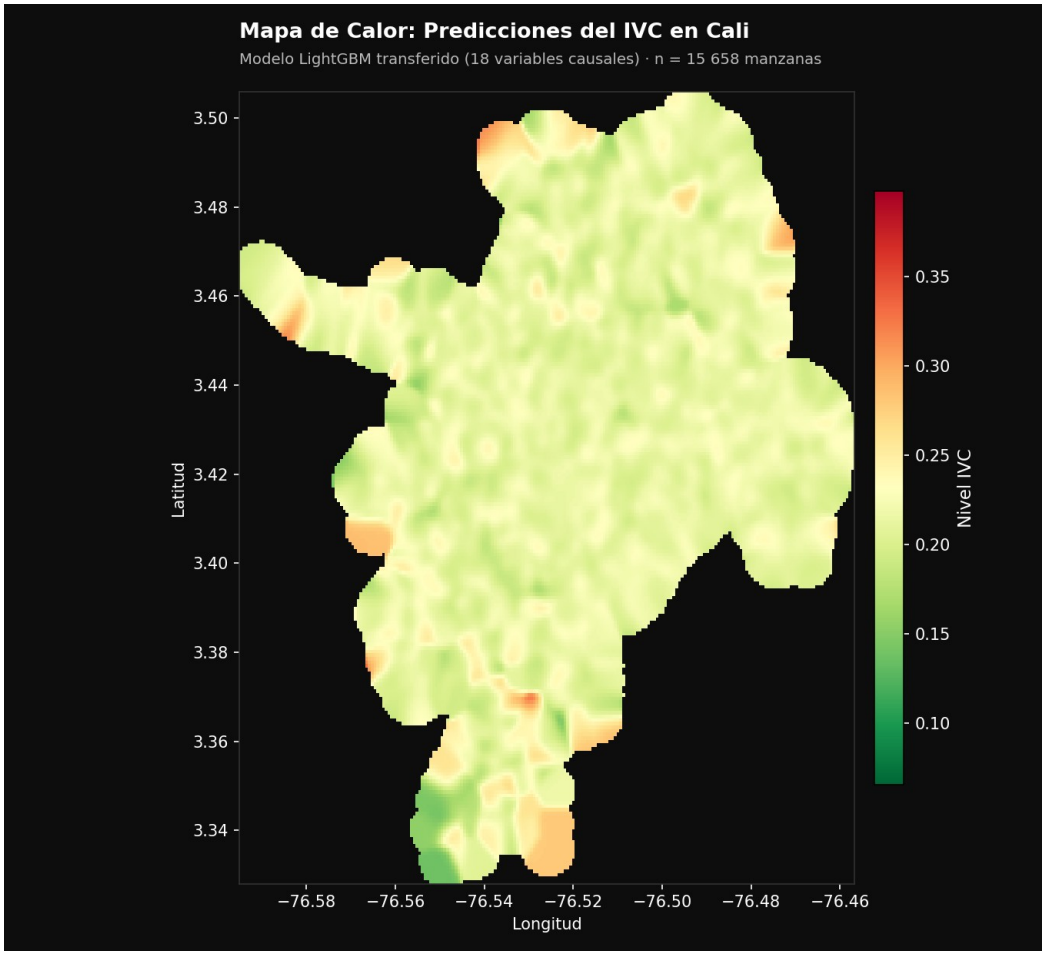


Figura 6. Mapa de calor de las predicciones del IVC en Bogotá generado sobre el conjunto de prueba.

La espacialización evidencia concentraciones de valores predichos relativamente altos en el sector suroccidental, incluyendo áreas de Ciudad Bolívar, Bosa y sectores de Usme y Sumapaz. El centro y el norte muestran predominantemente valores relativos menores. El mapa debe leerse como una representación de las estimaciones del modelo y no como una clasificación normativa independiente.

4.12 Transferencia del modelo a nuevas geografías: Medellín y Cali

Una vez evaluado el modelo en Bogotá, se planteó una segunda fase orientada a explorar su transferibilidad territorial. Para este propósito se construyó una versión simplificada, denominada en el desarrollo modelo independiente de la geografía específica, utilizando 18 variables socioeconómicas y climáticas y excluyendo deliberadamente latitud y longitud.

La exclusión de las coordenadas busca reducir la dependencia del modelo respecto de la configuración espacial particular de Bogotá y favorecer que la inferencia en otros territorios se apoye en atributos socioeconómicos, de servicios, educativos, climáticos y de contexto. Esta decisión no convierte el modelo en causal; simplemente modifica el conjunto de predictores para evaluar una forma más transferible de representación del problema.

```
top_18_features = [
    'TP19_INTE2','TP19_EE_E3','TP51POSTGR',
    'ppt_mean_2000_2018','TP19_EE_E2','TP19_EE_E1',
    'TP51PRIMAR','TP51SUPERI','TP14_3_TIP',
    'TP34_1_EDA','TP19_ACU_2','TVIVIENDA',
    'TP19_GAS_1','TP19_RECB2','TP19_ALC_1',
    'AREA','TP19_EE_E4','TP19_INTE1'
]

model_top18.fit(X_train[top_18_features], y_train)
joblib.dump(model_top18, 'modelo_ivc_nacional_top18.joblib')
```

La diferencia conceptual con Bogotá es fundamental: para Bogotá existe una variable objetivo observada que permite calcular métricas de desempeño. Para Medellín y Cali, en el escenario documentado, se generan estimaciones sin disponer de una variable IVC observada independiente que permita calcular R^2, MAE o RMSE locales. Por ello, los resultados de estas ciudades se presentan como transferencia de dominio e inferencia espacial, no como validación externa.

4.12.1 Aplicación en Medellín

El modelo independiente de la geografía específica se aplicó sobre 14.328 microdatos catastrales de Medellín. Se obtuvo un IVC predicho promedio de 0,2309, desviación estándar 0,0771, máximo 0,6047 y mínimo 0,0837. Se identificaron 144 registros en el 1 % superior, por encima del umbral crítico 0,4365.

ID / registro	Latitud	Longitud	IVC predicho
…10101-1	6,301288	−75,542563	0,299134
…10101-4	6,299384	−75,542372	0,288528
…10101-5	6,299333	−75,542817	0,273680
…10101-8	6,299935	−75,543699	0,290496
…10101-9	6,298994	−75,544830	0,143391

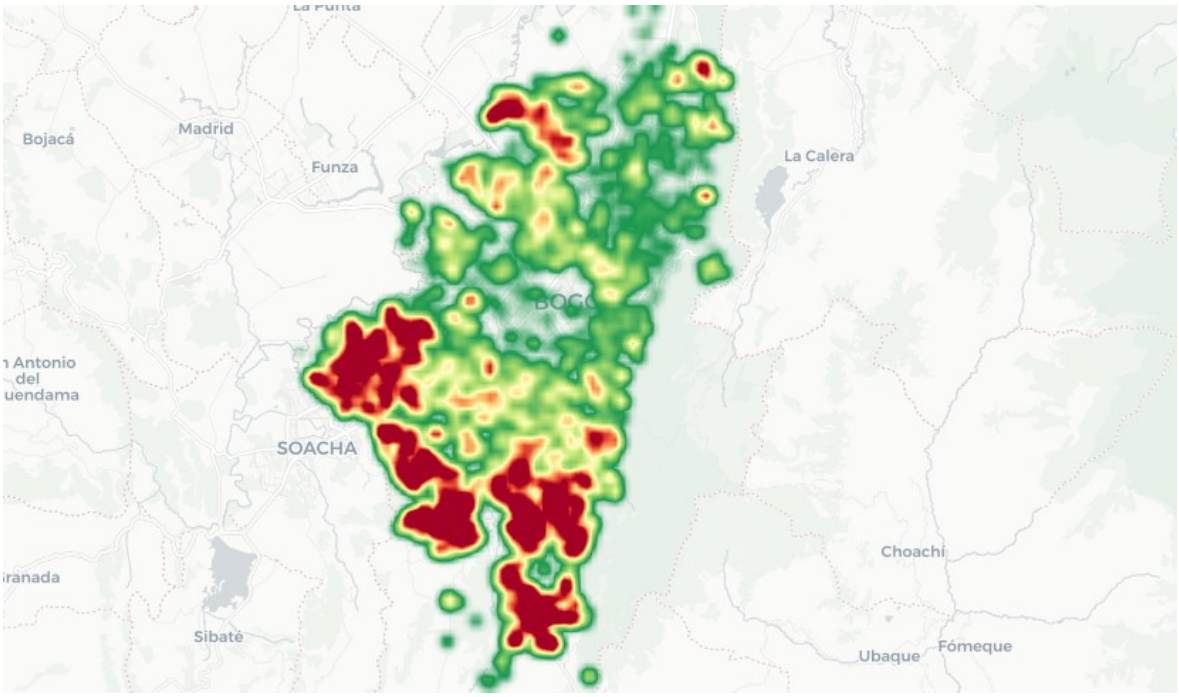


Figura 7. Espacialización de las predicciones del IVC en Medellín mediante el modelo transferido (n=14.328).

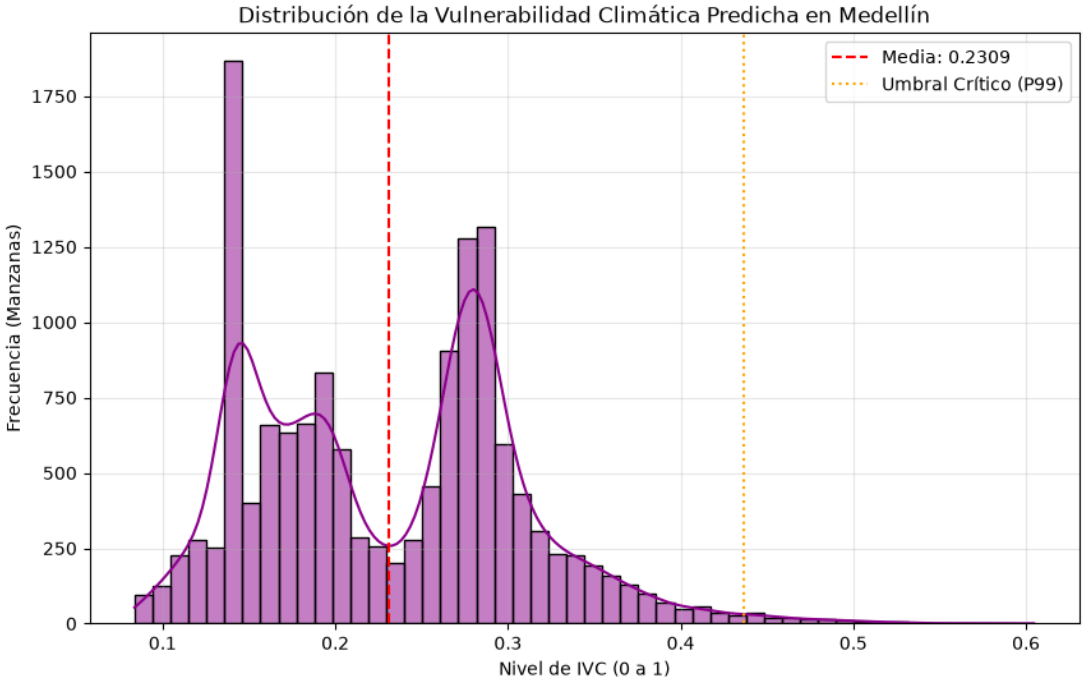


Figura 8. Distribución de la vulnerabilidad climática predicha en Medellín; se señalan la media y el umbral crítico P99.

Los productos espaciales permiten identificar áreas con valores relativos mayores dentro de Medellín. No obstante, la ausencia de un IVC observado local impide afirmar que dichas áreas presentan un nivel de error conocido o que la magnitud absoluta predicha sea equivalente a la magnitud observada.

4.12.2 Aplicación en Cali

El mismo modelo se aplicó a 15.658 unidades catastrales urbanas de Cali. Las predicciones se almacenaron en predicciones_ivc_cali_final.csv y se integraron con centroides geográficos en WGS 84.

ID / registro	Latitud	Longitud	IVC predicho
...010101-01	3,405586	−76,525777	0,233125
...010101-02	3,493018	−76,493492	0,280070
...010101-04	3,427837	−76,544045	0,199307
...010101-11	3,406159	−76,495833	0,276936
...010101-12	3,415629	−76,505503	0,229036

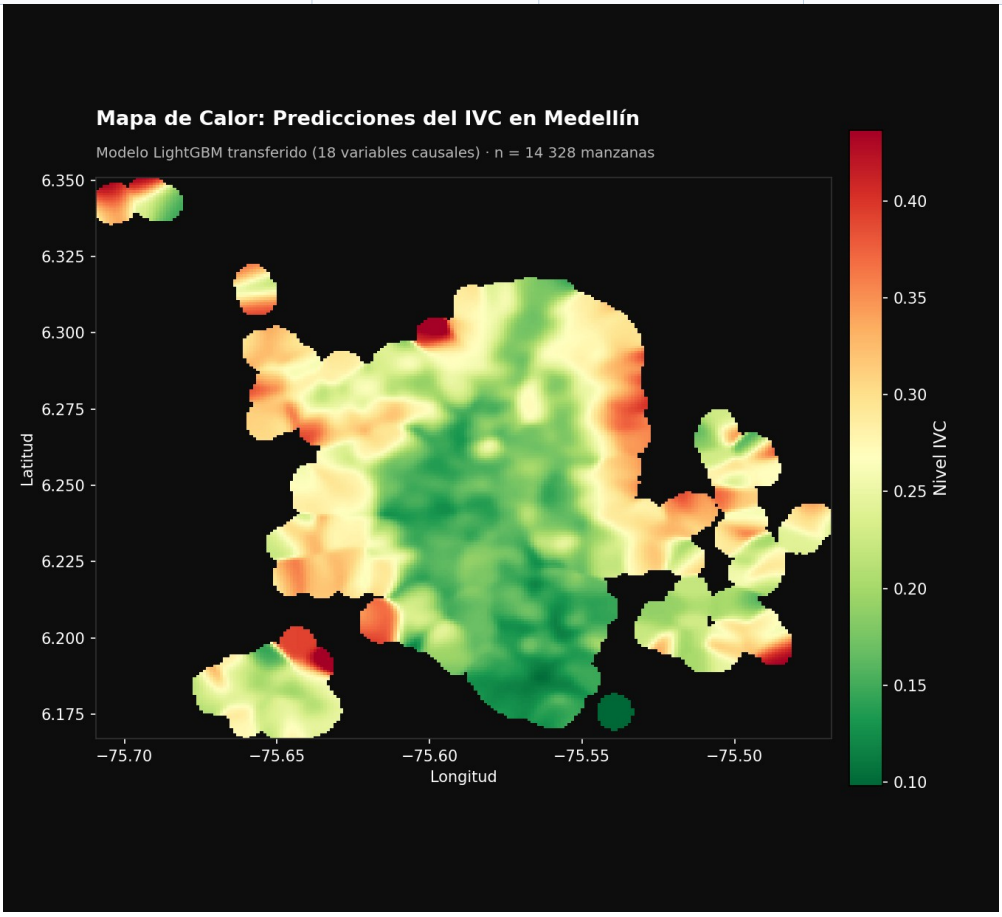


Figura 9. Espacialización de las predicciones del IVC en Cali a partir del modelo transferido (n=15.658).

La distribución espacial presenta núcleos de mayor vulnerabilidad predicha hacia sectores del norte, oriente y sur del área analizada, mientras que sectores centrales muestran valores relativos menores. Al igual que en Medellín, estos resultados son útiles para priorización exploratoria interna, pero requieren observaciones locales del IVC para evaluar precisión y calibrar la magnitud absoluta de las estimaciones.

4.13 Análisis comparativo interciudades

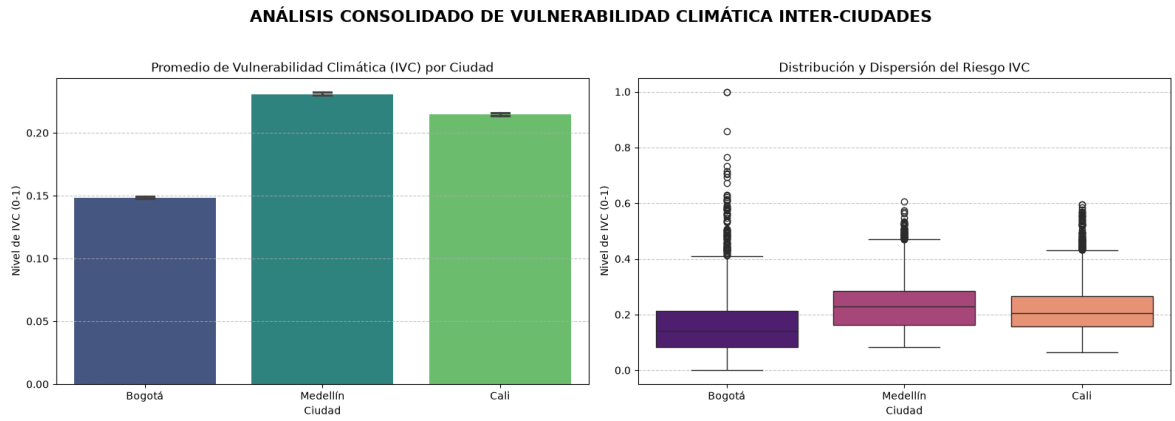


Figura 10. Comparación consolidada de la vulnerabilidad climática entre Bogotá, Medellín y Cali.

Métrica	Bogotá (base)	Medellín (transferido)	Diferencia
Media	0,1485	0,2309	+55,49 %
Desv. estándar	0,0772	0,0771	−0,13 %
Percentil 95	0,2636	0,3569	+35,38 %

El promedio predicho en Medellín es superior al promedio observado de Bogotá. Sin embargo, esta diferencia no debe interpretarse como evidencia concluyente de que Medellín tenga un IVC real 55,5 % superior al de Bogotá. El modelo fue entrenado en Bogotá y las predicciones para Medellín y Cali se encuentran fuera del dominio supervisado original. Las diferencias de distribución pueden reflejar tanto características territoriales reales como desplazamientos de dominio entre las bases de datos.

Por esta razón, el uso más prudente de esta transferencia es el análisis relativo dentro de cada ciudad: identificación de zonas con valores predichos altos, construcción de rankings y generación de mapas para orientar hipótesis de intervención. La comparación absoluta entre ciudades debe quedar condicionada a una futura validación con IVC observado localmente.

4.14 Preparación del modelo para despliegue (MLOps)

Como etapa final se generó una versión simplificada y serializada del pipeline, restringida a las variables de mayor importancia identificadas durante el análisis. El artefacto modelo_ivc_despliegue_top20.joblib permite reutilizar el modelo sobre nuevas bases de datos sin requerir el conjunto completo de variables originales.

```
loaded_model = joblib.load(
    'modelo_ivc_despliegue_top20.joblib'
)

nuevas_predicciones = loaded_model.predict(
    nueva_base_de_datos[top_20_features_raw]
)
```

Durante la recuperación del artefacto se documentó además una corrección de compatibilidad (fix_passthrough) relacionada con la serialización del transformador passthrough de scikit-learn y joblib. La identificación y resolución de este inconveniente forma parte de la trazabilidad técnica del modelo y demuestra que la aplicación no se limitó al ajuste estadístico, sino que consideró aspectos de reproducibilidad y reutilización del pipeline.

4.15 Discusión integrada de los resultados

La evidencia obtenida en este escenario computacional muestra que LightGBM presenta un desempeño predictivo estable para el IVC_n de Bogotá. El conjunto de prueba alcanzó R^2=0,8778, MAE=0,0170 y RMSE=0,0276, mientras que la validación cruzada produjo R^2=0,8757±0,0058. La proximidad entre ambos resultados es importante porque muestra que el desempeño no depende exclusivamente de una única división de los datos.

La diferencia entre R^2 de entrenamiento (0,8900) y prueba (0,8778) es reducida. Junto con las métricas de error y la validación K-Fold, esto sugiere un comportamiento de generalización interna adecuado. No obstante, la estabilidad dentro de Bogotá no elimina la posibilidad de desplazamiento de distribución cuando el modelo se aplica a otra ciudad.

El análisis de importancia evidencia que el modelo utiliza información de naturaleza socioeconómica, educativa, de servicios, climática y espacial. Esto respalda la concepción multidimensional del IVC, pero no permite establecer relaciones causales. En una investigación posterior sería pertinente complementar este análisis con métodos de explicabilidad como SHAP, análisis de sensibilidad y modelos espaciales de validación.

La transferencia a Medellín y Cali constituye una extensión aplicada de interés. La construcción de un modelo sin coordenadas específicas de Bogotá permite explorar una representación más generalizable, pero los resultados deben considerarse inferencias fuera del dominio de entrenamiento. La principal recomendación metodológica para una etapa posterior es construir o recuperar un IVC observado independiente para cada ciudad y efectuar una evaluación externa mediante R^2, MAE, RMSE y análisis espacial de residuos.

4.16 Síntesis del capítulo

Conjunto	R^2	MAE	RMSE
Train	0,8900	0,0164	0,0255
Test — K-Fold 10	0,8757	0,0170	0,0271
Test — Hold-out 10 %	0,8778	0,0170	0,0276

El presente capítulo documenta la ejecución formal de una configuración que había sido seleccionada previamente mediante un experimento en AWS SageMaker con PyCaret. La fase anterior permitió definir la proporción 90/10 y el enfoque LightGBM; la ejecución actual, desarrollada en un segundo entorno computacional, aportó la evaluación detallada mediante hold-out, K-Fold, análisis de sobreajuste, residuos, importancia de variables, predicciones individuales y espacialización.

La consistencia de los resultados entre SageMaker/PyCaret y la implementación nativa de LightGBM debe entenderse como evidencia de reproducibilidad y estabilidad computacional de la configuración seleccionada, no como validación externa. La validación externa requeriría datos independientes y, en el caso de Medellín y Cali, un IVC observado localmente.

En Bogotá, el modelo muestra capacidad predictiva elevada y estable. En Medellín y Cali, el modelo se utiliza como instrumento de transferencia e inferencia espacial para identificar patrones relativos y posibles zonas prioritarias. La utilidad de estas salidas para política pública debe complementarse con validación territorial antes de convertir las predicciones en estimaciones definitivas de vulnerabilidad.

Conclusión central: el escenario computacional desarrollado consolida un pipeline reproducible de Machine Learning para el IVC, con resultados cuantitativos sólidos en Bogotá y una ruta técnica para la transferencia espacial a otros territorios. La principal fortaleza metodológica reside en la secuencia selección previa → ejecución independiente → evaluación exhaustiva → transferencia, manteniendo una distinción explícita entre desempeño validado y predicción transferida.