SELECCIÓN Y EVALUACIÓN DEL MODELO DE MACHINE LEARNING PARA EL IVC

Índice de Vulnerabilidad de Bogotá D.C.

Modelo	LightGBM Regresión
Fuente de datos	Censo Nacional de Población y Vivienda 2018 (DANE)
Variable ambiental	Precipitación media satelital 2000–2018
Unidad de análisis	Manzanas urbanas de Bogotá (n = 43,408)
Variable objetivo	Índice de Vulnerabilidad Compuesto (IVC)
Fecha de análisis	2025

TABLA DE CONTENIDOS

1. Carga y Exploración Inicial de Datos
2. División Train / Test Estratificada
3. Entrenamiento del Modelo LightGBM
4. Validación Cruzada K-Fold (k=10)
5. Evaluación en Conjunto de Prueba
6. Análisis de Sobreajuste
7. Importancia de Variables
8. Análisis PhD — Interpretación de Variables
9. Tabla Resumen de Métricas
10. Visualización Geográfica
11. Preparación del Modelo para Despliegue

1. CARGA Y EXPLORACIÓN INICIAL DE DATOS

Se cargó el dataset de manzanas urbanas de Bogotá construido a partir del Censo Nacional de Población y Vivienda 2018 (DANE), enriquecido con la variable de precipitación media satelital (2000–2018). El conjunto cuenta con **43,408 registros** y **62 columnas**, de las cuales 56 son numéricas y 2 categóricas. Se detectaron únicamente 77 valores nulos en las columnas *NMB_LC_CM* y *TP_LC_CM*, lo que indica una alta integridad de los datos.

■ ***Código — Carga del dataset***

```
df = pd.read_csv('datos_ivc_bogota.csv')
print(f'Shape: {df.shape}')
print('Tipos de datos:', df.dtypes)
print('Valores nulos:', df.isnull().sum()()>0])
```

■ ***Salida***

```
Shape: (43408, 62)
Variables numéricas detectadas: 56
Variables categóricas detectadas: ['NMB_LC_CM', 'TP_LC_CM']
Valores nulos: NMB_LC_CM: 77 | TP_LC_CM: 77
```

Estadísticas Descriptivas Clave

Variable	Mín	Media	Máx	Descripción
LATITUD	3.890	4.625	4.833	Coordenada geográfica N-S
LONGITUD	-74.364	-74.117	-73.992	Coordenada geográfica E-O
AREA	32.2	7,333	1,274,400	Área de la manzana (m²)
ppt_mean_2000_2018	—	variable	—	Precipitación media satelital (mm)
ivc_n	0.0	—	1.0	Índice de Vulnerabilidad Compuesto (objetivo)

2. DIVISIÓN TRAIN / TEST ESTRATIFICADA

Se aplicó una división estratificada por categoría de vulnerabilidad (*categoria_ivc*) para preservar la distribución del índice en ambos conjuntos. El conjunto de entrenamiento representa el 80% de los datos y el conjunto de prueba (hold-out) el 20% restante.

■ ***Código — División y preprocesamiento***

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=42,
    stratify=df['categoria_ivc']
)

# Preprocesamiento: passthrough numérico, OneHotEncoder categórico
preprocessor = ColumnTransformer([
    ('num', 'passthrough', numeric_features),
    ('cat', OneHotEncoder(handle_unknown='ignore', sparse_output=False), categorical_features
)
])
```

Conjunto	Observaciones	Proporción
Entrenamiento (Train)	~34,726	80%
Prueba hold-out (Test)	~8,682	20%
Total	43,408	100%

3. ENTRENAMIENTO DEL MODELO LIGHTGBM

LightGBM (Light Gradient Boosting Machine) es un framework de boosting basado en árboles de decisión que utiliza histogramas para acelerar el entrenamiento y reducir el consumo de memoria. Es especialmente adecuado para datasets de gran escala con variables mixtas (numéricas y categóricas). El modelo se entrenó dentro de un *Pipeline* de scikit-learn que incorpora el preprocesamiento automáticamente.

■ ***Código — Configuración y entrenamiento***

```
params_lgbm = {
    'n_estimators': 100,
    'learning_rate': 0.1,
    'num_leaves': 31,
    'random_state': 42,
    'n_jobs': -1
}

pipeline = Pipeline(steps=[
    ('preprocessor', preprocessor),
    ('regressor', lgb.LGBMRegressor(**params_lgbm))
])

pipeline.fit(X_train, y_train)
```

■ ***Salida — Métricas de entrenamiento***

```
■ RESULTADOS EN CONJUNTO DE ENTRENAMIENTO:
  MAE:  0.016200
  RMSE: 0.025300
  R²:   0.892000
```

4. VALIDACIÓN CRUZADA K-FOLD (k=10)

Se realizó validación cruzada con **10 particiones (K-Fold)** para obtener una estimación robusta del desempeño del modelo y detectar posible sobreajuste. En cada fold se registraron las métricas R², MAE y RMSE tanto en train como en test.

■ ***Salida — Validación cruzada 10-Fold***

```
======================================================
VALIDACIÓN CRUZADA 10-Fold (n_estimators=100)
======================================================

R²:
  Test  → media: 0.8754  ±  0.0080
  Train → media: 0.8931  ±  0.0007

MAE:
  Test  → media: 0.0170  ±  0.0004
  Train → media: 0.0161  ±  0.0001

RMSE:
```

```
Test  → media: 0.0272  ±  0.0010
Train → media: 0.0252  ±  0.0001
```

La baja desviación estándar en todas las métricas (±0.008 en R^2) confirma que el modelo es estable y no depende de una partición específica de los datos.

5. EVALUACIÓN EN CONJUNTO DE PRUEBA

El modelo fue evaluado en el conjunto hold-out (datos que nunca vio durante el entrenamiento). Los resultados confirman la capacidad de generalización del modelo:

■ ***Salida — Métricas hold-out***

```
================================================
MÉTRICAS FINALES EN CONJUNTO DE PRUEBA
================================================
  R²   = 0.8784
  MAE  = 0.0169
  RMSE = 0.0271
```

Con un $R^2 = 0.878$, el modelo explica el 87.8% de la varianza del índice de vulnerabilidad. El MAE de 0.017 indica que el error promedio de predicción es de apenas 1.7 puntos porcentuales en la escala [0,1] del IVC.

6. ANÁLISIS DE SOBREAJUSTE

Para diagnosticar sobreajuste se compararon las métricas de entrenamiento contra las de prueba. Un modelo sobreajustado mostraría R^2 muy alto en train y bajo en test.

Métrica	Train	Test (hold-out)	Δ (Train – Test)
R^2	0.8920	0.8784	0.0136
MAE	0.0162	0.0169	-0.0007
RMSE	0.0253	0.0271	-0.0018

La diferencia entre train y test es mínima ($\Delta R^2 = 0.014$), lo que confirma **ausencia de sobreajuste significativo**. El modelo generaliza correctamente a datos no vistos durante el entrenamiento.

7. IMPORTANCIA DE VARIABLES (TOP 20)

LightGBM proporciona importancia de variables basada en la ganancia de información acumulada en todos los árboles. A mayor ganancia, mayor relevancia predictiva de la variable.

#	Variable	Importancia (Gain)	Categoría
1	**num__TP19_INTE2**	**390.61**	**Conectividad / Internet**
2	**num__TP19_EE_E3**	**294.38**	**Servicio eléctrico**
3	**num__TP51POSTGR**	**177.24**	**Educación (posgrado)**
4	**num__ppt_mean_2000_2018**	**129.95**	**Precipitación media (satelital)**
5	num__TP19_EE_E2	113.84	Servicio eléctrico
6	num__TP19_EE_E1	73.07	Servicio eléctrico

7	num__TP51PRIMAR	62.59	Educación (primaria)
8	num__TP51SUPERI	53.13	Educación (superior)
9	num__LATITUD	50.22	Geoespacial
10	num__TP14_3_TIP	21.92	Tipo de vivienda
11	num__TP34_1_EDA	12.95	Edad / Demografía
12	num__TP19_ACU_2	12.75	Servicio de acueducto
13	num__TVIVIENDA	11.82	Vivienda
14	num__LONGITUD	9.93	Geoespacial
15	num__TP19_GAS_1	9.37	Servicio de gas
16	num__TP19_RECB2	8.95	Recolección de basuras
17	num__TP19_ALC_1	8.61	Alcantarillado
18	num__AREA	8.09	Área de manzana
19	num__TP19_EE_E4	7.58	Servicio eléctrico
20	num__TP19_INTE1	6.00	Conectividad / Internet

★ Las primeras 4 variables (conectividad, energía eléctrica, educación de posgrado y precipitación satelital) concentran el ~74% de la importancia total del modelo.

8. ANÁLISIS DE IMPORTANCIA — INTERPRETACIÓN

■ num__TP19_INTE2 — Acceso a Internet (Tipo 2)

Variable de mayor peso con diferencia. El acceso a internet en el hogar actúa como proxy directo de exclusión socioeconómica digital. Las zonas sin conectividad presentan mayor vulnerabilidad compuesta, reflejando brechas estructurales de acceso.

■ num__TP19_EE_E3 — Servicio eléctrico (Estrato 3)

El segundo factor más influyente. La cobertura y tipo de servicio eléctrico es un indicador de infraestructura básica y nivel socioeconómico. Su presencia en el modelo indica diferenciación clara entre zonas con distintos niveles de servicio.

■ num__TP51POSTGR — Nivel educativo de posgrado

El capital humano avanzado opera como factor protector contra la vulnerabilidad. Las manzanas con mayor concentración de población con posgrado muestran índices de vulnerabilidad consistentemente más bajos.

■ num__ppt_mean_2000_2018 — Precipitación media satelital (2000–2018)

La variable ambiental ocupa el cuarto lugar, evidenciando que la vulnerabilidad en Bogotá tiene una dimensión territorial y climática relevante. Las zonas con mayor precipitación acumulada (sur y suroccidente) tienden a mayor vulnerabilidad, posiblemente por riesgo de inundación y deslizamientos.

■ Variables geoespaciales — LATITUD y LONGITUD

Su presencia en el top 10 confirma que existe una segregación territorial marcada en la ciudad. La ubicación geográfica captura heterogeneidades que las variables censales no explican completamente.

■ Variables de educación y servicios básicos

Múltiples niveles educativos (primaria, superior) y servicios como acueducto, gas y recolección de basuras contribuyen de manera moderada pero consistente, reforzando el carácter multidimensional del índice de vulnerabilidad.

9. TABLA RESUMEN DE MÉTRICAS FINALES

La siguiente tabla consolida las métricas de desempeño del modelo en los tres conjuntos de evaluación:

Conjunto	R^2	MAE	RMSE
Train	0.8920	0.0162	0.0253
Test (10-Fold CV)	0.8754	0.0170	0.0272
Test (hold-out)	0.8784	0.0169	0.0271

Interpretación: Un R^2 de 0.875–0.892 en todos los conjuntos, con desviación estándar de ±0.008 en validación cruzada, demuestra que el modelo LightGBM es **robusto, estable y generalizable**. El MAE de ~0.017 sobre la escala normalizada [0,1] implica un error promedio de menos de 2 puntos porcentuales en la predicción del índice de vulnerabilidad compuesto.

10. VISUALIZACIÓN GEOGRÁFICA

Se generaron visualizaciones geográficas de las predicciones del modelo sobre las manzanas del conjunto de prueba, utilizando coordenadas de latitud/longitud del censo. Los mapas permiten identificar los clústeres espaciales de alta y baja vulnerabilidad en Bogotá.

■ ***Código — Mapa coroplético interactivo***

```
import plotly.express as px

fig = px.scatter_mapbox(
    df_test,
    lat='LATITUD', lon='LONGITUD',
    color='ivc_pred',
    color_continuous_scale='RdYlGn_r',
    title='Índice de Vulnerabilidad Predicho — Bogotá D.C.',
    mapbox_style='carto-positron'
)
fig.show()
```

■ ***Salida***

```
■ Visualización generada exitosamente utilizando coordenadas
   geográficas del conjunto de prueba.

■ Archivo exportado: 'datos_vulnerabilidad_qgis.csv'
   Instrucciones para QGIS:
   1. Añadir capa de texto delimitado
   2. Campo X: LONGITUD | Campo Y: LATITUD
   3. SRC: EPSG:4326 - WGS 84
```

11. PREPARACIÓN DEL MODELO PARA DESPLIEGUE

Para facilitar la aplicación del modelo en nuevas bases de datos, se construyó un pipeline simplificado con las **20 variables más importantes**. Este pipeline incluye el preprocesador y el regresor entrenado, listo para

producción.

■ *Código — Exportación del modelo*

```
import joblib

# Pipeline de despliegue con Top 20 variables
deploy_pipeline = Pipeline(steps=[
    ('preprocessor', preprocessor_deploy),
    ('regressor', lgb.LGBMRegressor(**params_lgbm))
])

deploy_pipeline.fit(X[top_20_features_raw], y)
joblib.dump(deploy_pipeline, 'modelo_ivc_despliegue_top20.joblib')
```

■ *Salida*

```
Variables para despliegue:
ean_2000_2018',
 'TP19_EE_E2', 'TP19_EE_E1', 'TP51PRIMAR', 'TP51SUPERI', 'LATITUD',
 'TP14_3_TIP', 'TP34_1_EDA', 'TP19_ACU_2', 'TVIVIENDA', 'LONGITUD',
 'TP19_GAS_1', 'TP19_RECB2', 'TP19_ALC_1', 'AREA', 'TP19_EE_E4', 'TP19_INTE1']

■ Modelo guardado: 'modelo_ivc_despliegue_top20.joblib'
```

Uso en nueva base de datos

■ *Código — Inferencia en producción*

```
# Cargar y aplicar el modelo en producción
loaded_model = joblib.load('modelo_ivc_despliegue_top20.joblib')
nuevas_predicciones = loaded_model.predict(
    nueva_base_de_datos[top_20_features_raw]
)
```

El modelo LightGBM para el IVC de Bogotá alcanza un R^2 de 0.877–0.892 con estabilidad demostrada en validación cruzada 10-Fold, siendo apto para políticas de focalización territorial y toma de decisiones basada en datos.